밤의 증언

개인 기억과 근거 검증을 갖춘 AI 추리 게임

과제 2 · 신규 프로젝트

G075 김지원

주제와 주요 AI task

AI가 아는 정보의 범위와, 주장을 믿을 근거를 코드로 관리

01 참가자별 역할·관측·개인 판단 분리

02 MCP로 권한이 있는 기억만 조회

03 RAG로 질문에 필요한 기록 선택

04 핵심 주장 검증과 제한된 재검색·재작성

05 운영 모니터·MLflow 실험 비교·장애 대응

게임 구현 실행 화면

실제 OpenAI 게임 실행

사람의 질문 → AI의 공개 답변

역할·개인 기억은 참가자별 분리

공개 가능한 인용만 화면에 표시

자유 발언의 화자·위치 해석 오류는 남아 있음



같은 입력의 최신 검증 결과

코드 동결 후 확인한 합성 입력 22건 · 생성 24건 중 조건 위반 2건 제외

지표	이전	개선
올바른 판정	10/22	18/22
정상 발언 오차단	3/11	3/11
근거 없는 단정 누락	9/11	1/11
단정 수정 재시도 합계	2회	10회
검사 시간 · 사례별 중앙값 평균	0.0091 ms	0.0150 ms

추가 검증 LLM 0회 · 정상 오차단은 남음 · 수정 호출 비용 증가 가능

고정 출력 재생 평가. 실제 게임 승률·API 지연이 아님. 검토자는 구현 에이전트.

Agent Graph와 제한 재시도

기억 검색 → 생성 → 근거 검증 → 완료 / 재검색 / 재작성 / 기권

```
graph.add_node("memory", select)
graph.add_node("generate", generate)
graph.add_node("validate_evidence", validate_evidence)
graph.add_node("research", research)
graph.add_node("repair", repair)
graph.add_conditional_edges(
    "validate_evidence", after_validation,
    {"done": END, "research": "research",
     "repair": "repair", "fallback": "fallback"})
return graph.compile()
```

공통 그래프는 1회 컴파일 · 관측/상태는 매 판단 분리 · 생성 ≤3회, 재검색 ≤2회

game/decision.py · build_graph 발췌, 줄바꿈 조정

MCP 연결 재사용과 관측 권한

Resource: 근거 규칙 문서 / Tool: 현재 관측의 기억 검색

```
registered = await call('register_context',
    {'view': view, 'proof': signature(view, self.secret)})
token = registered['capability']
result = await call('search_memory',
    {'capability': token, 'query': query or '',
     'expanded': expanded})
# finally 블록에서 임시 관측 해제
await call('release_context', {'capability': token})
```

권한 필터 → 서명 → 임시 capability → 검색 → 해제

다른 참가자 ID를 지정해 비공개 기억을 조회하는 API를 제공하지 않음

game/mcp_memory.py · _serve 발췌, 주석·줄바꿈 보완

RAG: 게임 동의어·관련 표현 검색 보완

9개 검색 개념으로 표현 연결 · 임베딩/벡터 DB 미사용

```
def expanded_terms(text):
    return terms(text) + [
        "@concept:" + name for name in concepts(text)
    ]
```

거짓말 ↔ 진술 모순 **목격 ↔ 마주침** **보호 ↔ 치료**

관련 기록 검색에만 사용 · 원문·부정 표현·권한 필터 보존

추가 모델 호출 없음 · 등록하지 않은 바꿔 말하기는 누락 가능

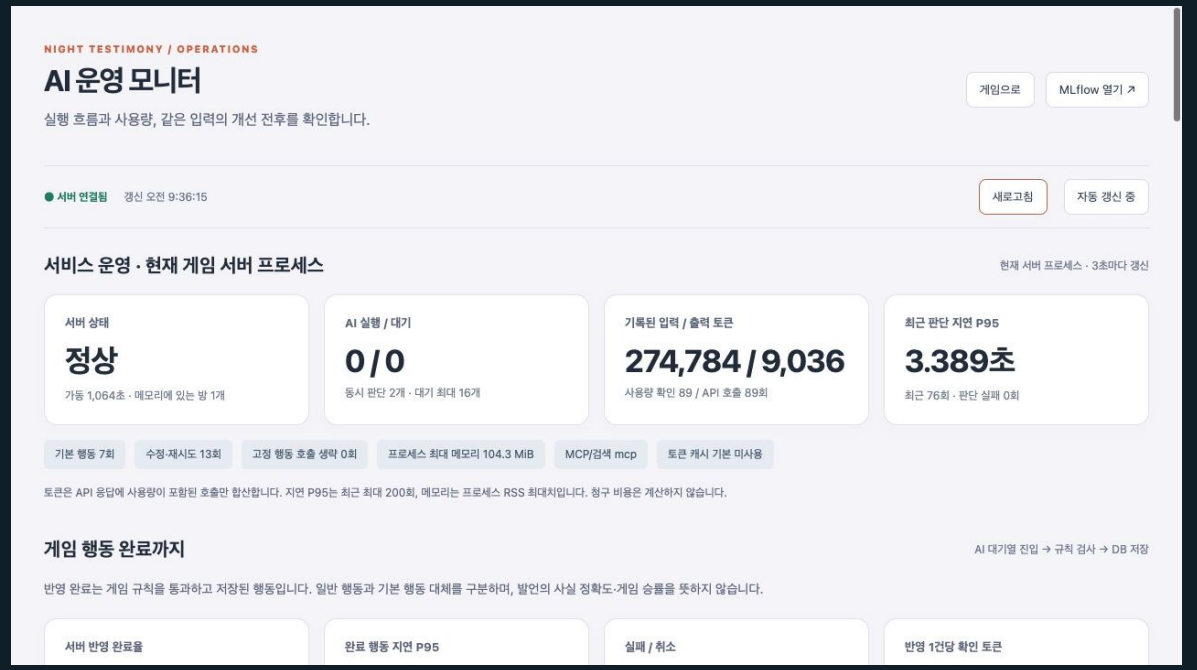
game/search_language.py · expanded_terms 발췌, 줄바꿈 조정. 검색 순위: game/memory.py

운영 모니터와 남은 한계

공통 자원 재사용, 개인 상태 분리

판단 → 규칙 적용 → DB 저장 추적
공통 연결 재사용 · 유한 대기열
Docker로 게임·MLflow 함께 실행

가상환경·Docker 각각 211개 통과
재시작 복원·MLflow 장애 격리 확인



실제 OpenAI 7인 게임 · 행동 76건 적용·저장

검증 강화는 수정 비용을 늘릴 수 있음 · 캐시는 실측 후 기본 비활성화

이후 개선: 사람 검수 평가, 복잡한 표현, 여러 서버 운영

동일 입력 전후 비교

OpenAI gpt-4.1-mini
근거 판단 8개 × 2회 / 조건별 16회

지표	전	후
기준 일치	10/16	16/16
평균 지연	1.287초	1.317초
입력 토큰	45,328	36,420
출력 토큰	746	932
재시도	0	0
고정 행동 모델 호출	4회	0회

고정 행동은 별도 2개 × 2회. 정확도·지연 표본에 섞지 않음.
승률·일반 추리 능력·청구 금액 평가가 아님.

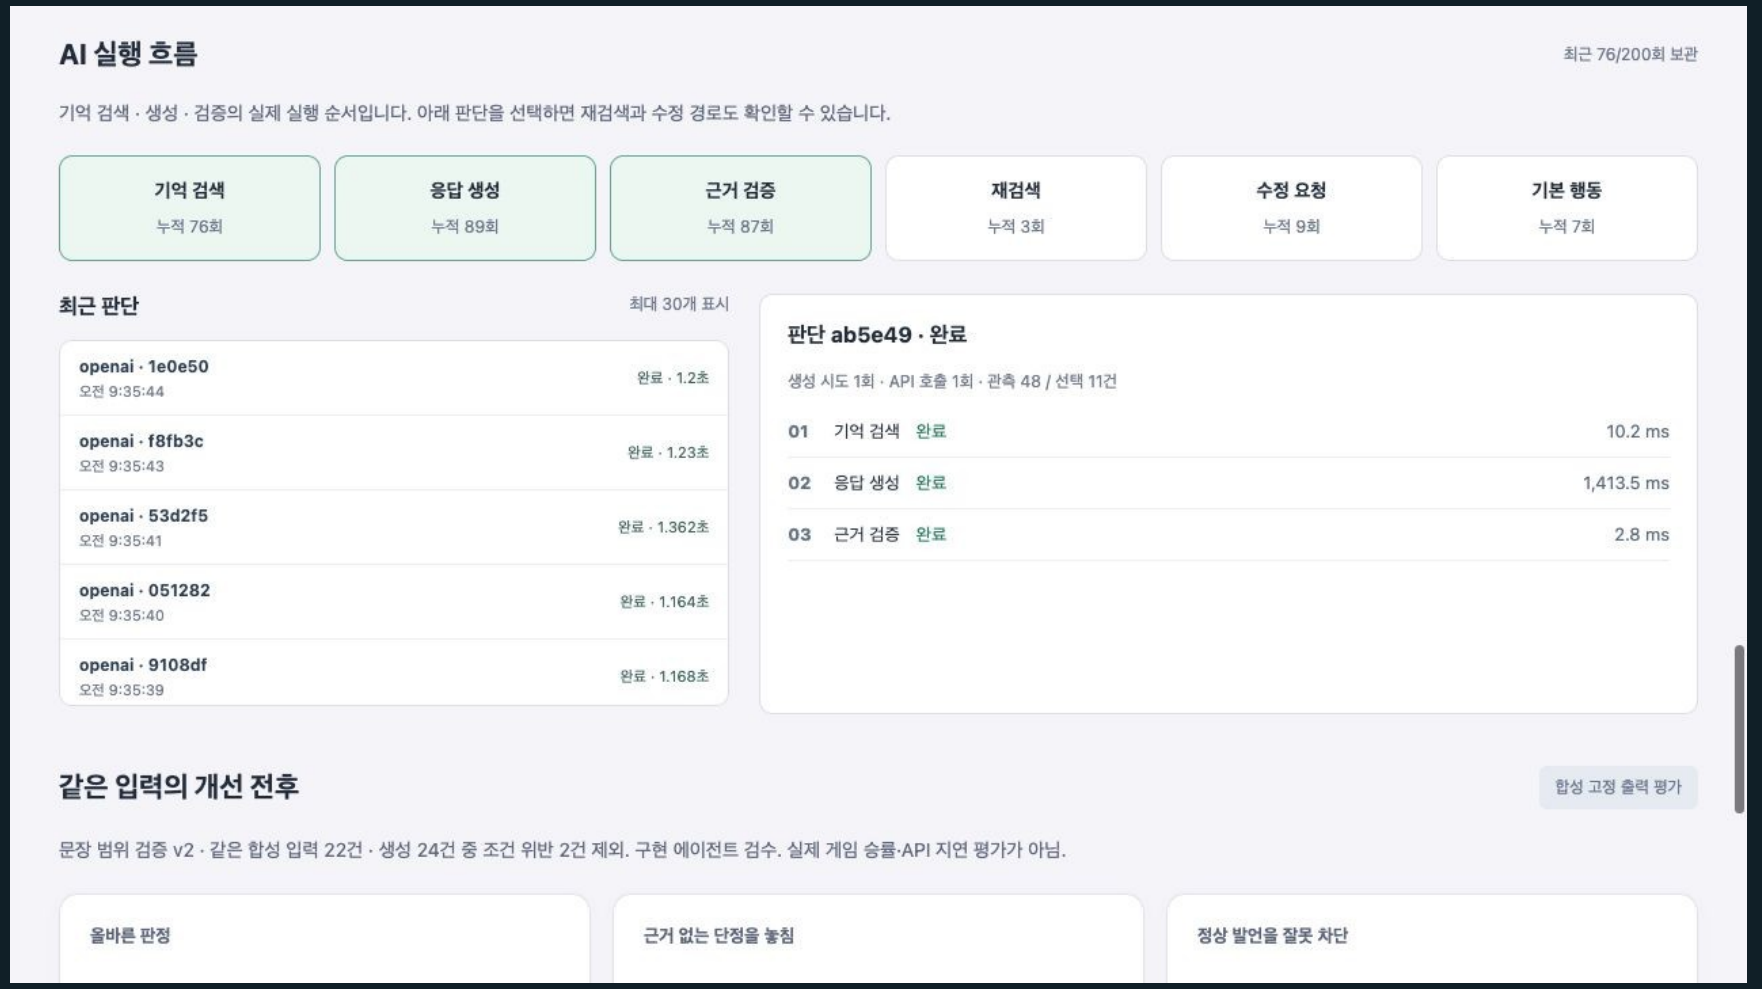
출처: reports/release-evaluation-v1.json
실제 API 응답 사용량 및 실행 시간 집계

부록 · 기술 요소와 코드 위치

기술 요소	적용 방식	대표 파일
Multi-Agent	참가자별 관측·역할·판단 분리	server.py / beliefs.py
MCP	서명된 관측, 임시 capability	mcp_memory.py
RAG	어휘·개념 확장과 중요 기록 보존	memory.py
DI·모듈화	모델·검색 의존성 주입	decision.py / providers.py
LangSmith	노드·검색·모델 상세 추적	@traceable
MLflow·운영 화면	숫자 지표·실험 비교·실행 흐름	mlflow_tracking.py
단위·통합 테스트	권한·복구·오류·동시성 211개	tests/

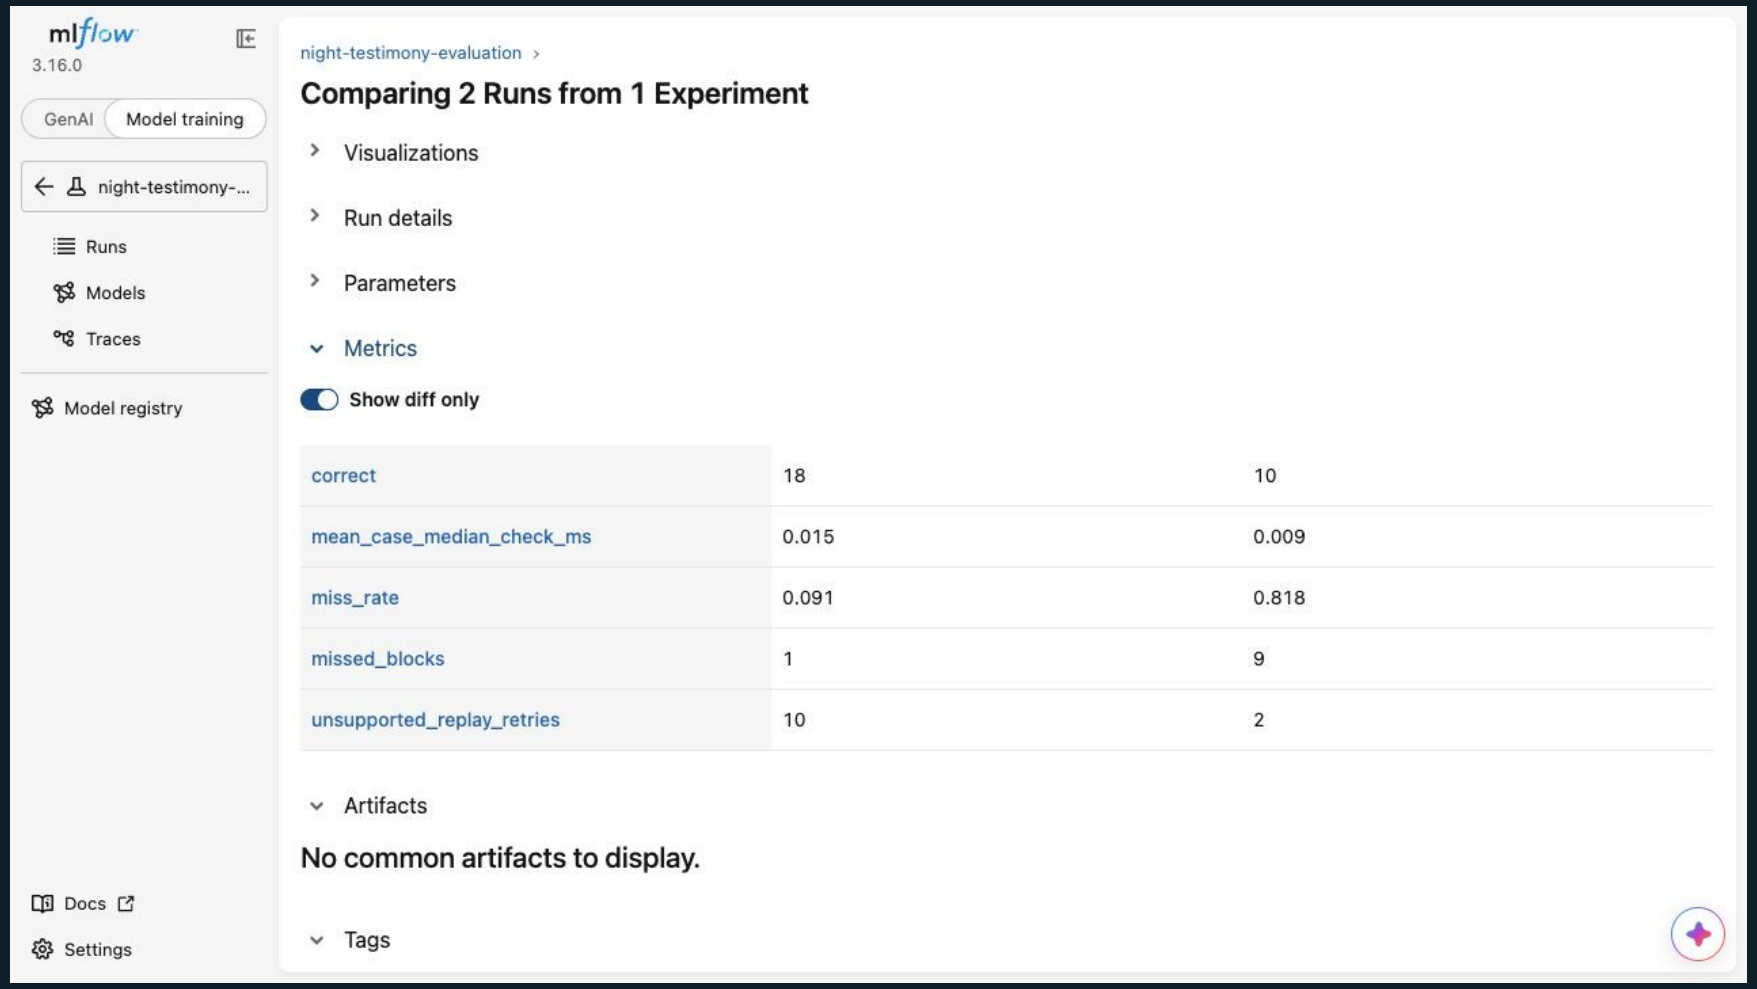
공개 저장소: github.com/xixvivji/deduction-game

부록 · AI 실행 흐름 화면



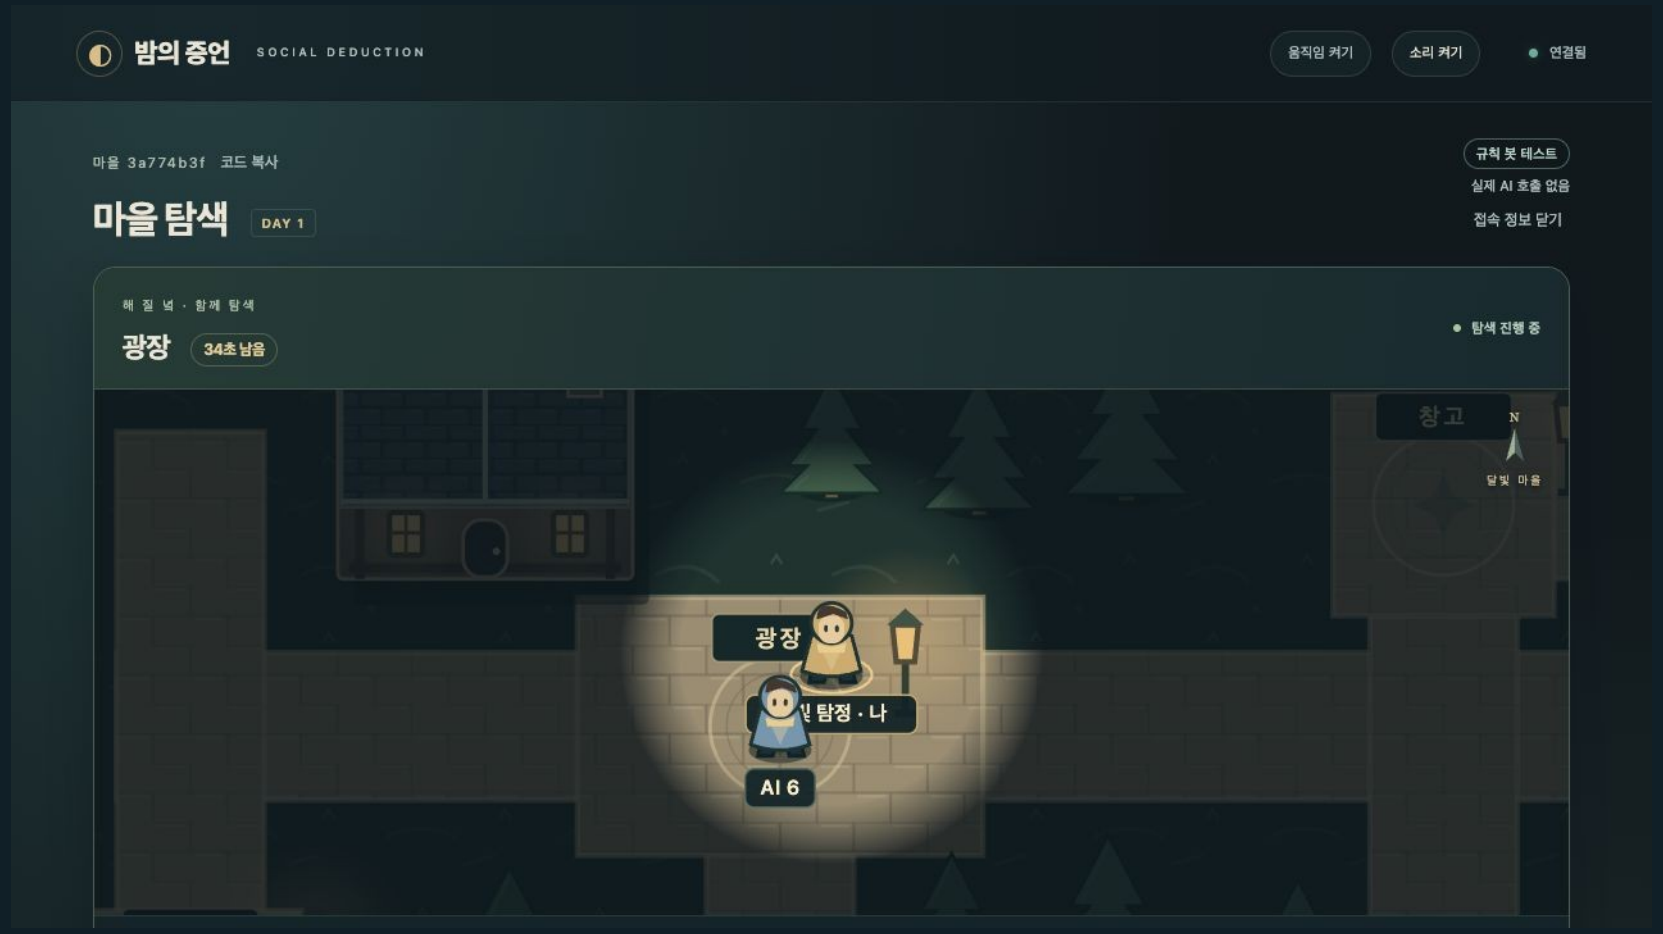
실제 OpenAI · API 89회 · 기본 행동 대체 7건 · 한 판의 통합 연결 검증

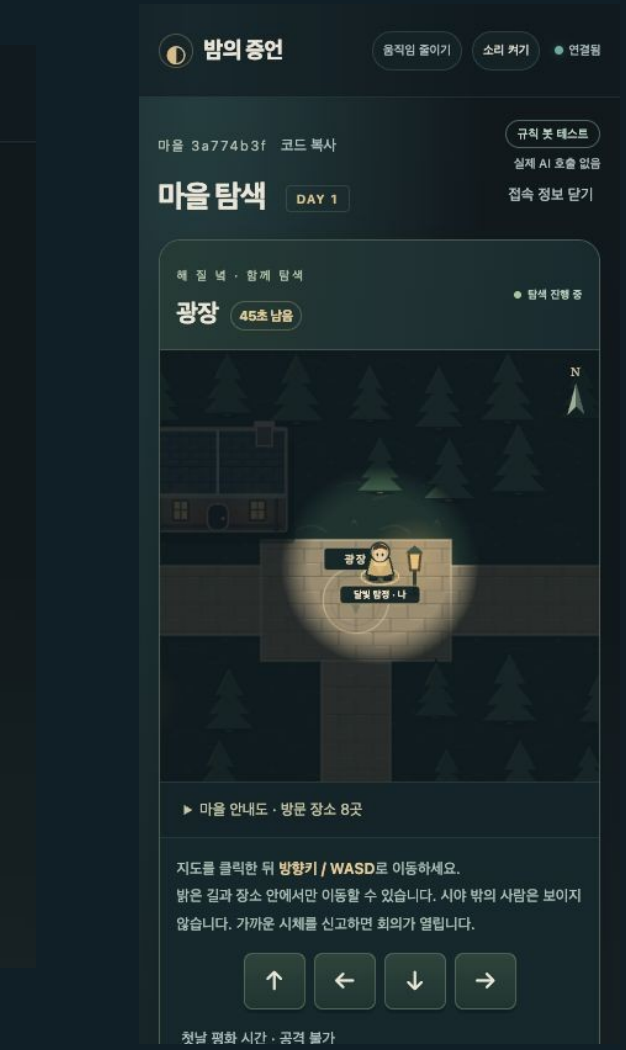
부록 · MLflow에 저장한 실험 비교



왼쪽 개선 / 오른쪽 이전 · 차이가 있는 지표만 표시 · 정상 오차단 3건은 동일

최종 화면 · 마을 탐색





돌길·건물·조명과 캐릭터 표현 정리

G075 김지원 · 13/13 · 규칙봇으로 화면·이동 점검